

Projeto 1 - Acompanhamento Obrigatório

Ciência de Dados - Análise Exploratória IBGE

Joey Alan

Paulo Henrico

Fortaleza, CE - 31 de agosto de 2026

1 Identificação do Projeto

Tema: Tema 1 - Economia e Emprego Formal no Ceará.

Integrantes da Equipe: Joey Alan e Paulo Henrico.

Repositório GitHub: <https://github.com/JoeyAlanS/Projeto-01-emprego-formal>

Problema central: Como a estrutura econômica dos municípios cearenses se relaciona com a intensidade de ocupação formal, remuneração média e dinâmica populacional do Censo 2022?

Perguntas de Análise (Missão):

1. Quais municípios possuem a maior intensidade de ocupação formal e como isso reflete no seu Produto Interno Bruto (PIB) *per capita*?
2. Como as participações setoriais (Agropecuária, Indústria, Serviços e Adm. Pública) associam-se ao salário médio mensal municipal?
3. Existe concentração espacial do emprego formal em relação aos polos de maior crescimento populacional relativo desde 2010?

Divisão de Responsabilidades (2 Integrantes):

- **Joey Alan (Engenharia de Dados e Infraestrutura):**

- Organização das camadas de dados (*raw*, *processed*, *analytical*) e reprodutibilidade no GitHub.
- Ingestão, validação de chaves e tratamento sistemático de tipos e símbolos especiais do SIDRA.
- Construção dos pipelines de integração relacional (1 : 1) por código IBGE de 7 dígitos.

- **Paulo Henrico (Análise Exploratória, Visualização e Dashboard):**

- Condução da análise exploratória nos notebooks e derivação dos insights analíticos.
- Geração de gráficos, mapas coropléticos com GeoPandas e diagramação da interface.
- Desenvolvimento da aplicação Streamlit (consumo de arquivos estáticos locais).

2 Inventário Inicial de Dados

O pacote de dados original (camada *raw*) compreende as seguintes bases oficiais:

Tabela (Fonte)	Ano	Grão	Chave	Unidade(s)	Principais Campos
9509 - CEMPRE	2022	Mun. (N6)	territorio_codigo	Unidades, Pes- soas, R\$	Unidades locais, ocupa- ção total/assalariada, salário médio mensal.
5938 - Estrutura	2021	Mun. (N6)	territorio_codigo	Mil R\$, %	VAB Setoriais e par- ticipações setoriais no VAB total.
5938 - PIB Total	2022	Mun. (N6)	territorio_codigo	Mil R\$	PIB a preços correntes.
4709 - Censo	2022	Mun. (N6)	territorio_codigo	Pessoas, %	População residente, variação absoluta e taxa geométrica.
Malha GeoJSON	2022	Polígonos	codarea	Coordenadas (°)	Geometria dos 184 mu- nicípios para suporte cartográfico.

3 Diagnóstico de Qualidade e Higienização

A equipe executou rotinas de diagnóstico via Pandas para auditar a qualidade:

- **Duplicatas:** Checagem com a chave composta ['territorio_codigo', 'ano_codigo', 'variavel_codigo']. **Resultado:** Zero duplicatas.
- **Valores Ausentes:** No recorte estrito municipal (`nivel_territorial_codigo == 'N6'`), não há células vazias (NaN).
- **Símbolos Especiais do SIDRA:** Aplicou-se coerção numérica com `pd.to_numeric(errors='coerce')`. Não foram encontradas anomalias impeditivas ou campos suprimidos nas variáveis selecionadas.
- **Integridade de Tipos:** Chaves territoriais (`territorio_codigo` e `codarea`) são tratadas estritamente como texto (*string*) para preservar o prefixo estadual "23" e zeros à esquerda. Registros de nível Brasil (N1) e Ceará (N3) foram isolados para não inflar métricas municipais.

4 Primeiro Cruzamento Reprodutível

Para validar o fluxo de preparação, cruzamos "PIB Total 2022" e "Censo 2022 (População Residente)" para calcular o **PIB per capita 2022**.

- **Chave de junção:** `territorio_codigo` (código IBGE de 7 dígitos).
- **Cardinalidade esperada:** 1 : 1 (1 observação de PIB e 1 de população por município).
- **Métricas do Cruzamento (Inner Join):**
 - **Correspondências exatas (Matches):** 184 municípios (100%).
 - **Não correspondências (Unmatched):** 0 municípios (0%).
- **Normalização da Escala:** Multiplicação do PIB por 1.000 (de Mil R\$ para R\$) antes da divisão por pessoas residentes.

5 Visualizações Preliminares e Reprodutibilidade

A extração e o pareamento foram executados pelo script abaixo:

```
1 import pandas as pd
2
3 # Carga preservando tipos categoricos
4 df_pib = pd.read_csv("dados/raw/t5938_pib_2022_ce_br.csv", sep=";", dtype={"
    territorio_codigo": str})
5 df_pop = pd.read_csv("dados/raw/t4709_populacao_censo_2022_ce_br.csv", sep=";", dtype={"
    territorio_codigo": str})
6
7 # Filtragem de nivel municipal (N6) e variaveis alvo
8 pib_n6 = df_pib[df_pib["nivel_territorial_codigo"] == "N6"][["territorio_codigo", "
    territorio_nome", "valor"]].rename(columns={"valor": "pib"})
9 pop_n6 = df_pop[(df_pop["nivel_territorial_codigo"] == "N6") & (df_pop["variavel_codigo"] ==
    "93")][["territorio_codigo", "valor"]].rename(columns={"valor": "populacao"})
10
11 # Pareamento e calculo
12 df_analitica = pd.merge(pib_n6, pop_n6, on="territorio_codigo", how="inner")
13 df_analitica["pib"] = pd.to_numeric(df_analitica["pib"])
14 df_analitica["populacao"] = pd.to_numeric(df_analitica["populacao"])
15 df_analitica["pib_per_capita"] = (df_analitica["pib"] * 1000) / df_analitica["populacao"]
```

Listing 1: Pipeline de pareamento e derivação de dados.




Figura 1: Top 5: PIB per Capita (2022)




Figura 2: Dispersão: População vs PIB

Interpretações Iniciais: O Gráfico 1 evidencia a concentração de valor agregado em polos industriais e logísticos, com destaque para São Gonçalo do Amarante (Complexo do Pecém). O Gráfico 2 indica correlação positiva geral entre escala populacional e PIB total, mas a distribuição *per capita* é fortemente influenciada pela especialização produtiva do município.

6 Limitações Metodológicas e Cuidados Analíticos

Em conformidade com as diretrizes do projeto:

- **Defasagem Temporal:** O cruzamento da composição setorial (2021) com CEMPRE/Censo (2022) representa uma aproximação exploratória de 1 ano, e não um retrato simultâneo.
- **Natureza dos Dados de Emprego:** O CEMPRE abrange apenas empresas e organizações formais ativas com CNPJ. A métrica de ocupados por habitante será denominada **intensidade de ocupação formal**, reconhecendo que não mede a taxa de emprego total nem o trabalho informal.

- **Conclusões Observacionais:** Nenhuma associação estatística observada será interpretada como relação de causalidade direta.

7 Wireframe do Dashboard

Estrutura visual da aplicação interativa em desenvolvimento no Streamlit:




Figura 3: Layout do dashboard para exploração dos dados municipais.