
Projeto 1 – Acompanhamento Obrigatório

Ciência de Dados – Análise Exploratória com Dados do IBGE

Joey Alan e Paulo Henrico

1. Identificação do Projeto

Tema: Tema 1 – Economia e Emprego Formal no Ceará.

Repositório: <https://github.com/JoeyAlanS/Projeto-01-emprego-formal>

Problema central: como a estrutura econômica dos municípios cearenses se relaciona com a intensidade de ocupação formal, remuneração média e dinâmica populacional?

Perguntas de análise:

1. Quais municípios apresentam os maiores valores de PIB por habitante em 2022?
2. Como o PIB por habitante se associa à intensidade de ocupação formal em 2022?
3. Como salário médio mensal, proporção de assalariados e crescimento populacional variam entre os municípios?
4. Como a composição setorial de 2021 se associa aos indicadores do CEMPRE de 2022, reconhecendo a defasagem de um ano?

2. Divisão de Responsabilidades

Joey Alan	Leitura e inventário dos arquivos brutos; auditoria de tipos, chaves, duplicatas e símbolos SIDRA; definição e validação das junções pelo código IBGE.
Paulo Henrico	Análise exploratória; elaboração das visualizações preliminares; desenho do wireframe e programação da aplicação em Streamlit.
Ambos	Revisão das interpretações, registro das limitações, preparação da apresentação de status e validação da reprodutibilidade.

Recorte: 184 municípios do Ceará. PIB, população e CEMPRE usam 2022; a composição econômica usa 2021.

3. Inventário Inicial dos Dados Brutos

Os CSVs estão em formato longo, separados por ponto e vírgula, codificados em UTF-8 com BOM e contêm os níveis Brasil (N1), Ceará (N3) e Município (N6). Para a análise municipal, somente N6 é utilizado.

Base raw	Ano	Linhas	N6	Variáveis	Conteúdo e unidades
9509 – CEMPRE	2022	1.116	1.104	6	Unidades locais, empresas, ocupados, assalariados, salários (Mil R\$) e salário médio mensal (R\$).
5938 – Estrutura	2021	1.860	1.840	10	PIB, VAB total e setorial, valores em Mil R\$ e participações em %.
5938 – PIB total	2022	186	184	1	Produto Interno Bruto a preços correntes, em Mil R\$.
4709 – Censo	2022	558	552	3	População residente, variação absoluta e crescimento geométrico, em pessoas e %.
Malha GeoJSON	2022	184 feições	184	–	Polígonos municipais; chave cartográfica codarea .

Chave: `territorio_codigo`, preservada como texto com sete dígitos. Na malha, a chave equivalente é **codarea**. O nome municipal é apenas descritivo e não participa do pareamento.

4. Diagnóstico de Qualidade

Cobertura territorial	Cada CSV contém 184 códigos municipais distintos. O GeoJSON possui 184 feições e 184 valores únicos de codarea .
Duplicatas	Zero duplicatas na chave composta territorio_codigo + ano_codigo + variavel_codigo nos quatro CSVs.
Ausências	Zero células vazias na coluna valor dos arquivos fornecidos. A conversão numérica deve ser feita somente após preservar o valor original.
Símbolos SIDRA	Foram pesquisados literalmente -, 0, X, . . e . . .: zero ocorrências nos quatro CSVs. A rotina continuará registrando a contagem; 0 será preservado como zero numérico e os demais símbolos serão sinalizados antes da coerção.
Níveis territoriais	N1 e N3 serão mantidos como referências, mas excluídos de somas, rankings e junções municipais para evitar dupla contagem.
Malha	Nenhuma geometria ausente. O README bruto registra pequenas auto-interseções em cinco feições; isso deve ser considerado se houver operação espacial além de mapa temático.

5. Decisões Iniciais de Tratamento

- preservar os arquivos raw sem sobrescrita e manter **valor** original;
- criar cópia numérica apenas para cálculo, com relatório de coerções;
- filtrar N6 e cada código de variável antes de pivotar ou juntar;
- validar cardinalidade **one_to_one** e medir **left_only**, **right_only** e **both**;
- multiplicar o PIB em Mil R\$ por 1.000 antes de dividi-lo pela população.

6. Primeiro Cruzamento Reproduzível

O primeiro cruzamento usa três tabelas obrigatórias: PIB 2022 (variável 37), população residente 2022 (variável 93) e pessoal ocupado total do CEMPRES 2022 (variável 707). Após filtrar N6, cada recorte possui uma observação por código municipal.



Resultado medido diretamente nos arquivos raw: PIB + população = 184 correspondências (100%), 0 somente à esquerda e 0 somente à direita. Ao acrescentar CEMPRES, permanecem 184 correspondências (100%) e 0 não correspondências.

Listing 1: Leitura, auditoria e junção diretamente da camada raw.

```

1 import pandas as pd
2
3 TIPOS = {"territorio_codigo": "string", "variavel_codigo": "string"}
4
5 def ler(nome):
6     return pd.read_csv(
7         f"dados/raw/{nome}", sep=";", encoding="utf-8-sig",
8         dtype=TIPOS, keep_default_na=False
9     )
10
11 def selecionar(df, codigo, novo_nome):
12     recorte = df[
13         (df["nivel_territorial_codigo"] == "N6") &
14         (df["variavel_codigo"] == codigo)
15     ][["territorio_codigo", "territorio_nome", "valor"]].copy()
16     recorte[novo_nome] = pd.to_numeric(recorte.pop("valor"), errors="coerce")
17     return recorte
18
19 pib = selecionar(ler("t5938_pib_2022_ce_br.csv"), "37", "pib_mil_reais")
20 pop = selecionar(ler("t4709_populacao_censo_2022_ce_br.csv"), "93", "populacao")
21 ocup = selecionar(ler("t9509_cempre_economia_emprego_2022_ce_br.csv"), "707", "ocupados")
22
23 base = pib.merge(
24     pop.drop(columns="territorio_nome"), on="territorio_codigo",
25     how="outer", indicator=True, validate="one_to_one"
26 )
27 base = base.drop(columns="_merge").merge(
28     ocup.drop(columns="territorio_nome"), on="territorio_codigo",
29     how="outer", indicator=True, validate="one_to_one"
30 )
31 base["pib_per_capita"] = base["pib_mil_reais"] * 1000 / base["populacao"]
32 base["intensidade_formal"] = base["ocupados"] * 1000 / base["populacao"]
  
```

7. Visualização Preliminar 1 – PIB por Habitante




Figura 1: Cinco maiores PIBs por habitante, calculados com PIB e população de 2022.

8. Visualização Preliminar 2 – Cruzamento PIB, Censo e CEMPRE




Figura 2: PIB por habitante versus intensidade de ocupação formal nos 184 municípios. As linhas tracejadas representam as medianas.

Interpretações iniciais baseadas apenas nos dados:

- São Gonçalo do Amarante apresenta o maior PIB por habitante (R\$ 127.332); o valor não equivale à renda individual nem informa como a produção é distribuída.
- A mediana municipal é R\$ 13.088 por habitante e 102,8 ocupados formais por mil habitantes.
- A correlação linear entre os dois indicadores é 0,69, associação positiva de intensidade moderada/alta no recorte; não demonstra causalidade.
- Eusébio se destaca pela intensidade formal de aproximadamente 700,7 ocupados por mil habitantes. O indicador pode superar padrões residenciais porque o CEMPRE mede postos localizados nas organizações, não somente trabalhadores residentes.

9. Limitações Metodológicas

- O CEMPRE cobre organizações formais e não representa o trabalho informal.
- A estrutura econômica é de 2021; cruzamentos com CEMPRE e Censo de 2022 têm defasagem de um ano.
- PIB, VAB e remunerações são nominais; variações entre anos não equivalem a crescimento real sem ajuste de preços.
- Associações territoriais observadas não sustentam conclusões causais.

10. Wireframe do Dashboard




Figura 3: Estrutura planejada para o dashboard Streamlit.

Comportamento previsto:

- estado inicial com todos os municípios e unidades/períodos visíveis;
- filtros coerentes, com mensagem clara quando não houver linhas;
- mapa integrado por **codare**, nunca por nome municipal;
- seção “Fontes e metodologia” com tabelas, anos, fórmulas e limitações;
- pelo menos dois visuais derivados da integração entre bases.

11. Próximos Passos

1. transformar a auditoria raw em pipeline reproduzível para as camadas **processed** e **analytical**;
2. validar indicadores derivados e documentar linhas sem correspondência em cada junção;
3. implementar e publicar o dashboard com arquivos estáticos;
4. preparar slides, pitch, vídeo extensionista e registros da DreamShaper.